

. EIT 问题的有限元表达

定义在区域 Ω 下， Σ 为边界， u 为区域内的电压， e_l 为电极区域。完备电极下的 CEM 方程如下：

$$\begin{aligned}\Omega: \nabla \cdot (\sigma \nabla u) &= 0, \text{ in } \Omega \\ \Gamma_2: \sigma \frac{\partial u}{\partial n} &= 0, \text{ (无电极区)} \\ \Gamma'_2: \sigma \frac{\partial u}{\partial n} &= -J_n, \text{ (电极注入区域)} \\ \Gamma_3: u + z_l \sigma \frac{\partial u}{\partial n} &= u_l, \text{ (测量电极区)}\end{aligned}$$

则泛函表达为

$$\begin{aligned}I(u) &= \frac{1}{2} \iint_{\Omega} \sigma (\nabla u)^2 dx dy - \int_{\Gamma'_2} \frac{1}{z_l} \left(\frac{1}{2} u^2 - u_l u \right) d\Gamma'_2 \\ \frac{\partial I}{\partial u_i} &= \sum_{j=1}^n u_j \int_{\Omega} \sigma (\nabla N_j \cdot \nabla N_i) d\Omega + \int_{\Sigma} J_n N_i d\Sigma \\ \int_{\Gamma^e} J_n N_i d\Sigma &= \frac{I}{\Delta^e} \int_{\Gamma^e} N_i d\Gamma^e = -I/2 \\ S_{i,j} &= \int_{\Omega} \sigma (\nabla N_j \cdot \nabla N_i) d\Omega, F_i = - \int_{\Sigma} J_n N_i d\Sigma, SU = F\end{aligned}$$

所以 $F \in \mathbb{R}^{n \times 1}$ 为 $[1 \ -1 \ 0 \ 0 \ 0 \ 0]$ 的向量。 $S \in \mathbb{R}^{n \times n}$ 为整体系数矩阵， n 为节点个数。

. EIT 逆问题

利用有限元方法（FEM）建立人体模型，EIT 重建问题可以转化为如下的最优化为题，选择合适的 x 使得 $F(x)$ 最小

$$\hat{x} = \arg \min_x \{ \|y - Jx\|_p^p + \lambda \|\phi(x)\|_q^q \}$$

其中 $y \in \mathbb{R}^{n_M}$ 两帧图像之间的电压差，其中 n_M 为电压测量次数。 $\hat{x} \in \mathbb{R}^{n_N}$ 是用于成像的阻抗变化， n_N 为模型中有限元个数。 $J \in \mathbb{R}^{n_M \times n_N}$ is the jacobian；在我们的设备中 $n_M = n_E n_V = 16 * 13 = 208$ ；其中 λ is the hyper parameter，正则化项 $\phi(x)$ 的选取十分关键，可以把一些先验知识通过 $\phi(x)$ 加入到最优化的过程中。 $\phi(x)$ 一般可以表达为 $\phi(x) = Lx$ 的形式。 L 的选取有很多种方法，例如 NOSER, Tikhonov, Laplace, exponential covariance, Gaussian HPF and time smooth prior 等。 zeroth-order Tikhonov regularization 方法 $L = I$ 为单位阵。 NOSRE 方法中 L 为对角阵[1]，定义如下式所示：

$$[L^T L]_{i,i} = [J^T J]_{i,i}$$

p, q 能够采用不同的组合。如果 $p = q = 2$ 为 Tikhonov regularization，可以直接采用 One

step Gauss-Newton 方法求解:

$$\hat{x} = Ry = [(J^T J + \lambda^2 L^T L)^{-1} J^T] y$$

GREIT 也是一种基于 L2-L2 的方法[2], 它首先建立了规范化的成人和婴儿的胸部 FEM 模型, 定义了衡量图像质量的若干准则, 提出了一种基于大量仿真数据扰动的方法来获得重构矩阵的框架。L2-L2 的方法为一种线性方法, 有限元模型确定以后 R 是固定的, 因此直接通过 $\hat{x} = Ry$ 获得图像, 计算速度很快, 目前的实时成像系统一般采用这种方法。

Wang 的研究中, $p = 2, q = 1, \phi(x) = x$ 。这是一种 $\ell_2 \ell_1$ 的方法, 由于 $\|\phi(x)\|_1^1$ 不可导, 需要采用迭代方法来求解。Wang 采用了 Split Bregman iterative algorithm (SB) 算法[3], 并与 A fast iterative shrinkage-thresholding algorithm (FISTA)[4] 和 interior-point 方法 [5] 进行了对比。论文采用 492 有限元的模型, SB 算法进行一次求解的运算时间为 0.2364s (单个正则化参数), 比 FIST 和 IP 方法更为快速。论文同时与 TV 和 $\ell_2 \ell_2$ 方法进行了对比, 结果 L2-L1 的方法具有更高的精度。

Mamatjan 提出了 primal-dual interior point method (PDIPM) algorithm 对来解决 L1 范式求解问题, 该方法可以求解各种范式组合[6]。The computation time (CPU time) for an increasing number of iterations was calculated, where it took 1.4 s for $\ell_1 \ell_2$, 2.3 s for $\ell_2 \ell_1$. $\ell_2 \ell_2$ took the least computation time (0.9 s), while $\ell_1 \ell_1$ took the most computation time (5.7 s) based on the stable solution that they produced. The results showed that an ℓ_1 solution is not only more robust to unavoidable measurement errors in a clinical setting, but. it also provides high contrast resolution on organ boundaries.

Borsic 提出了一种 Total variation (TV) 正则化的方法[7], TV 定义如下公式所示, 其中 k 代表边的编号, 标号为 $m(k)$ 和 $n(k)$ 有限元(elements)的共同边为 k , 边的长度为 l_k 。 $L_k = [0, 0, 0, l_k, 0, 0, -l_k, \dots]$, $L_k \in \mathbb{R}^{n_N}$, 为矩阵化后的结果。TV 公式的物理意义可以这么理解: 如果两个有限元相邻, 而且公共边的长度很长, 那么我们希望这两个有限元的差值较小。

$$\phi(x) = TV(x) = \sum_k l_k |x_{m(k)} - x_{n(k)}| = \sum_k |L_k x|$$

TV 方法转化为如下的最优化问题 $L = [L_1^T, \dots, L_k^T, \dots, L_{n_k}^T]^T$, $L \in \mathbb{R}^{n_K n_N}$, 可以看出 TV 方法的正则项为 L1-norm。Javaherian 提出了 TVAL3 方法来加速 L2-TV 性能[8], 该方法基于 ADMM 方法。

还有一些其他的方法, 例如 Ranade and Gharpure [9] 提出了一种局部松弛正则化(locally relaxing regularization)方法来提高图像的尖锐特征。Liu, Khambampati [10] 提出了一种基于参数化水平集的方法能够显著的提高成像质量。

Integrated EIT

tidal volume, end-expiratory lung volume change ($\Delta EELV$), compliance, ventilation delay, and over distension/collapse images were performed. Clinically useful parameters were successfully extracted including anterior/posterior ventilation ratio (A/P ratio), center of ventilation (CoVx, CoVy), global inhomogeneity (GI), coefficient of variation (CV), ventilation delay and percentile of overdistension/collapse[11].

程序实现：

令 N_n 为有限元节点数, N_e 为有限元个数, N_E 为电极个数,总共进行 N_E 次刺激,每次刺激有 $N_v = N_E - 3$ 次测量电压,总测量次数 $N_m = N_E N_v$ 。 $\sigma \in \mathbb{R}^{N_e}$ 为有限元的电阻值, $U \in \mathbb{R}^{N_n}$ 为节点电压。

首先计算系统矩阵 S :

$$S_{i,j} = \int_{\Omega} \sigma(\nabla N_j \cdot \nabla N_i) d\Omega$$

实际计算时,先获得 ∇N_i^e 矩阵, $e = 1, 2, \dots, N_e, i = 1, 2, \dots, N_n$ 。对于2D模型 ∇N_i^e 为二维数组,对于3D模型 ∇N_i^e 为三维数组。在eidor中采用system_mat_fields计算获得 ∇N_i^e 矩阵,存储为 $F_c \in \mathbb{R}^{2N_n \times N_e}$,该矩阵存储了 ∇N_i^e 的数值。随后利用 F_c 和 σ 利用计算系统矩阵 S 。计算方式为 $S = F_c' * \text{kron}(\sigma, 2) * F_c$, $S \in \mathbb{R}^{N_n \times N_n}$ 。随后计算矩阵 $F \in \mathbb{R}^{N_n}$ 。如下所示:

$$F_i = - \int_{\Sigma} J_n N_i d\Sigma$$

依据推导 F 只有激励电极处该值为1或者-1,其他为0。这样可以依据公式 $SU = F$ 求得节点电压分布 U : $U = \text{left_divide}(S, F)$ 。

前向模型求解: (system_mat_1st_order)

- 1) 采用 system_mat_fields 计算获得 $2N_n * N_e$ 的矩阵 FC , 这个矩阵只和有限元模型相关。
- 2) 把 $N_e * 1$ 的 elem_data 扩展为 $2048 * 1$, 利用 spdiags 变为稀疏对角阵 ES
- 3) $E = FC' * ES * FC$, $s_mat = 1/2 * (E.' + E)$, 获得 s_mat 为 $N_n * N_n$ 的系统矩阵 S 。
- 4) 通过有限元公式可知: $S * U = F$, 其中 U ($545 * 1$) 为节点电压, F ($545 * 1$) 为电流源激励矩阵, F 中只有电流刺激的地方为 $1/-1$, 其他的为 0 。
- 5) $U = \text{left_divide}(S, F)$; 获得前向的电压
- 6) 针对16个电流刺激, 可以计算获得16个电压分布

对于逆问题, 首先要求解jacobian矩阵 J 。矩阵 J 的计算首先需要计算 ∇N_i^e , 获得 F_c 矩阵。随后令 Y 为电极电压, 对于第 i 次刺激可以得到公式 $F_c' * x * F_c * Y_k = F_k$ 。随后可以计算获得 $J_{ij}^k = \frac{\partial [Y_k]_i}{\partial [x]_j} \Big|_{\sigma_r}$, $i = 1, 2, \dots, N_v, j = 1, 2, \dots, N_n$ 。 J_{ij}^k 公式代表如下意义: 在第 k 次刺激模式下, 如果 $[x]_j$ 变化一定数值 σ_r 会导致 $[Y_k]_i$ 变化多少。重复 N_E 次上述过程, 并排列好后可以获得整个jacobian矩阵 $J \in \mathbb{R}^{[N_E N_v] \times N_n}$ 。 J 的计算采用的jacobian_adjoint函数计算。随后可以用正则化的方法求解图像 \hat{x} 。

$$\hat{x} = \arg \min_x \{ \|y - Jx\|^2 + \lambda^2 \|Lx\|^2 \}$$

```
img_bkgnd= calc_jacobian_bkgnd( inv_model );  
J = calc_jacobian( img_bkgnd );  
RtR = calc_RtR_prior( inv_model );  
W = calc_meas_icov( inv_model );  
hp = calc_hyperparameter( inv_model );  
RM = left_divide( (J'*W*J + hp^2*RtR), J'*W );
```

获得了RM后, 第一点的电压为 v_h , 后一点的电压为 v_i . 需要计算他们之间的差分图像。

- 1) 调用calc_difference_data函数计算差分值，计算有两种方式，一种为直接相减，第二种为归一化差分 $dva = vi./vh-1$
- 2) 计算有限元上的阻抗变化: `elem_data = imdl.solve_use_matrix.RM*dva;`
- 3) 调用`show_slices(imr)`显示图像，这个函数做了如下工作。
 - 1、调用`coarse2fine`进行插值 `imr.fwd_model.coarse2fine* elem_data`。
`elem_data`的数据长度和`imr.fwd_model.elems`的长度不一样，我的理解是计算时只计算了一部分有限元的数值，需要通过插值函数来还原出所有有限元的数据。
 - 2、调用`calc_slices`获得64*64的图像数据。取某一个剖面的有限元的阻抗图像。
 - 3、然后进行渲染后，获得最终画出来的图像。
- 4) `elem_ptr = mdl_slice_mapper(fwd_model, 'elem');`

已知: `RM, vi, vh, coarse2fine, elem_ptr` 就可以计算了

```
dva = vi(vh~=0)./vh(vi~=0)-1;
elem_data = imdl.solve_use_matrix.RM* dva;
elem_data = imr.fwd_model.coarse2fine*elem_data;
elem_ptr = mdl_slice_mapper( imr.fwd_model, 'elem' );
backgnd= NaN;
n_images= size(elem_data,2);
rval= backgnd*ones(size(elem_data)+[1,0]);
rval(2:end,:) = elem_data;
rimg= reshape( rval(elem_ptr+1,:), [size(elem_ptr), 1]);
img_out1 = calc_colours( rimg, img); % 颜色映射
image(img_out1);
```

附录

1. 格林公式

利用变分法，E-L方程和格林公式，可以把偏微分方程，例如laplace方程和poisson方程转化为积分方程。其中格林公式主要解决边界条件问题。设如下泛函

$$I(u) = \iint_{\Omega} F(x, y, u(x, y), u_x, u_y) dx dy + \int_{\Sigma} G(s, u, u_s) ds$$

其E-L方程为：

$$\frac{\partial F}{\partial u} - \frac{\partial}{\partial x} \left(\frac{\partial F}{\partial u_x} \right) - \frac{\partial}{\partial y} \left(\frac{\partial F}{\partial u_y} \right) = 0$$

$$\left(\frac{\partial F}{\partial u_x} \frac{dy}{ds} - \frac{\partial F}{\partial u_y} \frac{dx}{ds} + \frac{\partial G}{\partial u} - \frac{d}{ds} \left(\frac{\partial G}{\partial u_s} \right) \right) \bigg|_{\Sigma} = 0$$

l1-norm 求解

1、ADMM

ADMM 算法代码见\EIT\code\matlab\ADMM

Matlab中对于 **tall arrays** 数据，lasso回归采用 Alternating Direction Method of Multipliers (ADMM)方法求解.对于如下问题求解如下问题：

$$\arg \min_{x,z} \{f(x) + g(z)\}, \text{sub. to } Ax + Bz = C$$

ADMM方法用采用如下步骤求解：

$$\text{Step1: } x^{k+1} = \arg \min_x \left\{ f(x) + \frac{\rho}{2} \|Ax^k + Bz^k - c + u^k\|_2^2 \right\}$$

$$\text{Step2: } z^{k+1} = \arg \min_z \left\{ g(z) + \frac{\rho}{2} \|Ax^k + Bz^k - c + u^k\|_2^2 \right\}$$

$$\text{Step3: } u^{k+1} = u^k + Ax^{k+1} + Bz^{k+1} - c$$

其中 u^k 为scaled dual variable，或者Lagrange multiplier， ρ 为Lagrangian parameter。

对于Generalized Lasso回归 $\arg \min_x \left\{ \frac{1}{2} \|b - Ax\|^2 + \lambda \|Fx\|_1 \right\}$ ，令 $f(x) = \|b - Ax\|^2$ ， $g(z) = \lambda \|Fz\|_1$ 。

$$\hat{x} = \arg \min_x \left\{ \frac{1}{2} \|b - Ax\|^2 + \lambda \|z\|_1 \right\}, \text{sub. to } Fx - z = 0$$

第一步，固定 z^k ， u^k ，求解最优的 x^{k+1}

$$\arg \min_x \left\{ \frac{1}{2} \|b - Ax\|^2 + \frac{\rho}{2} \|x^k - z^k + u^k\|_2^2 \right\}$$

$$A'Ax - A'b + \rho F'Fx + \rho F'(u^k - z^k) = 0$$

$$x^{k+1} = (A'A + \rho F'F)^{-1}(A'b + \rho F'(z^k - u^k))$$

第二步，固定 x^{k+1} ， u^k ，求解最优的 z^{k+1}

$$\arg \min_z \left\{ \lambda \|z\|_1 + \frac{\rho}{2} \|x^k - z^k + u^k\|_2^2 \right\}$$

对于 l1-norm 求解，引入了 soft thresholding operator 函数 S_k

$$S_k(a) = \begin{cases} a - k, & a > k \\ 0, & -k < a < k \\ a + k, & a < -k \end{cases}$$

得到

$$z^{k+1} = S_{\lambda/\rho}(Fx^{k+1} + u^k)$$

第三步：

$$u^{k+1} = u^k + (Fx^{k+1} - z^{k+1})$$

所以 ADMM 方法主要用于 L2-L1 范式。

2、IRN

首先采用 Half-Quadratic (HQ) 来解决非 2 范式的最小化问题, 由 HQ 技术可以得到下式, 其中 $0 < p < 2$ 。这里 $\alpha = \frac{p}{2-p}$, $\varepsilon = \frac{\frac{2}{2^{2-p}}}{(2-p)*p^{2-p}}$, 当 $v^* = \frac{p}{2}|t|^{p-2}$ 时, 函数达到极小值[19]。 vt^2 为 2 次, $\frac{1}{\varepsilon v^\alpha}$ 为非二次, 所以叫做半二次。

$ t ^p = \min_{v>0} \{vt^2 + \frac{1}{\varepsilon v^\alpha}\}, \quad \varepsilon > 0, \alpha > 0$	(4)
---	-----

HQ 算法已经被证明了与线性梯度迭代之间的等效性, 同时也可以很方便的扩展到多个约束条件的正则化中。对于单个约束条件的正则化问题的来说,

$\min_x \left\{ \frac{1}{q} \ Ax - b\ _q^q + \frac{\lambda}{p} \ Lx\ _p^p \right\}$	(5)
---	-----

式中, L 为约束条件对应的正则算子, λ 为对应的正则化参数, q -th 和 p -th 表示对应的范数, 使用极小交替法 (alternating minimization iterative procedure), 可以得到:

$W_F^{k+1} = \text{diag}(Ax^k - b ^{q-2})$	(6)
---	-----

$W_{R_i}^{k+1} = \text{diag}(Lx^k ^{p-2})$	(7)
---	-----

$x^{k+1} = \min_x \left\{ \left\ (W_F^{k+1})^{\frac{1}{2}} (Ax^k - b) \right\ _2^2 + \left\ (W_R^{k+1})^{\frac{1}{2}} Lx^k \right\ _2^2 \right\}$	(8)
---	-----

最小均方问题(8)对应的正规方程为:

$(A^T W_F^{k+1} A + \lambda L^T W_R^{k+1} L) x^{k+1} = A^T W_F^{k+1} b$	(9)
---	-----

求解方程(9)就可以得到 x^{k+1} , 按照上述迭代关系,, IRN 算法流程如下:

算法 2.1

输入: A , 传递矩阵, L , 正则矩阵, λ 为正则参数

输出: x^*

1. $x^0 = (A^T A + \lambda L^T L)^{-1} A^T b$ or $x^0 = \tilde{x}$
2. **while** $k = 0, 1, 2 \dots, n$ **do**
3. compute W_F^{k+1} and W_R^{k+1} by (9) and (10)
4. compute x^{k+1} by solving the linear system (12)
5. **if** $\text{norm}(x^{k+1} - x^k) / \text{norm}(x^k) < \text{tol}$, **break**; **endif**
6. **end while**
7. $x^* = x^{k+1}$

IRN 算法代码见 \EIT\code\matlab\IRN

3、PDIPM 算法

参考文献：

1. Cheney, M., et al., *NOSER: An algorithm for solving the inverse conductivity problem*. International Journal of Imaging systems and technology, 1990. **2**(2): p. 66-75.
2. Adler, A., et al., *GREIT: a unified approach to 2D linear EIT reconstruction of lung images*. Physiological measurement, 2009. **30**(6): p. S35.
3. Wang, J., et al., *Split Bregman iterative algorithm for sparse reconstruction of electrical impedance tomography*. Signal Processing, 2012. **92**(12): p. 2952-2961.
4. Beck, A. and M. Teboulle, *A fast iterative shrinkage-thresholding algorithm for linear inverse problems*. SIAM journal on imaging sciences, 2009. **2**(1): p. 183-202.
5. Kim, S., et al., *An interior-point method for large-scale ℓ_1 -regularized least squares*. IEEE J. Sel. Top. Signal Process. **1**(4).
6. Mamatjan, Y., et al., *An experimental clinical evaluation of EIT imaging with ℓ_1 data and image norms*. Physiological measurement, 2013. **34**(9): p. 1027.
7. Borsic, A., et al., *Total variation regularization in electrical impedance tomography*. 2007.
8. Javaherian, A., et al., *An accelerated version of alternating direction method of multipliers for TV minimization in EIT*. Applied Mathematical Modelling, 2016. **40**(21-22): p. 8985-9000.
9. Ranade, N.V. and D.C. Gharpure, *Enhancing sharp features by locally relaxing regularization for reconstructed images in electrical impedance tomography*. Journal of Electrical Bioimpedance, 2019. **10**(1): p. 2-13.
10. Liu, D., A.K. Khambampati, and J. Du, *A parametric level set method for electrical impedance tomography*. IEEE transactions on medical imaging, 2017. **37**(2): p. 451-460.
11. Jang, G.Y., et al., *Integrated EIT system for functional lung ventilation imaging*. Biomedical engineering online, 2019. **18**(1): p. 83.
12. Dai, T. and A. Adler. *Electrical Impedance Tomography reconstruction using ℓ_1 norms for data and image terms*. in *2008 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*. 2008. IEEE.